TUGAS 05 - ADVANCED CNNs AND TRANSFER LEARNING

Muhammad Luthfi Hidayat | NIM 2802495700

Latar belakang dan konteks masalah

Klasifikasi ras hewan dengan data terbatas membutuhkan fitur yang mampu membedakan bentuk wajah dan pola bulu. Eksperimen membandingkan training dari nol, feature extraction, fine-tuning, serta augmentasi untuk menilai performa dan biaya adaptasi model pretrained (slide 14-16, 27-29) [7].

A1. BatchNorm dan regularisasi (slide 6-8)

Batch Normalization menghitung mean dan variance dari mini-batch saat training. Komposisi sampel berubah antarbatches sehingga representasi sebuah citra juga dipengaruhi citra lain dalam batch. Variasi ini memberi noise pada aktivasi ternormalisasi dan dapat mengurangi ketergantungan model pada pola tertentu. Efek tersebut menjelaskan sifat regularisasi ringan, tetapi tidak menjamin Dropout selalu tidak diperlukan. Pada dataset sangat kecil atau classifier berkapasitas besar, model masih dapat overfit sehingga regularisasi tambahan perlu diuji melalui validation set. Batch sangat kecil atau tidak representatif juga membuat estimasi statistik tidak stabil. Masalah ini berbeda dari overfitting akibat menghapus Dropout. Jika BatchNorm berjalan dalam eval mode, sumber noise statistik mini-batch tersebut tidak aktif. Karena itu, manfaat regularisasinya tidak boleh diasumsikan tetap sama. [1]

A2. Degradasi dan residual connection (slide 10-12)

Jaringan lebih dalam secara teoritis dapat meniru jaringan dangkal dengan membuat lapisan tambahan sebagai identity mapping. Namun, keberadaan solusi tersebut tidak berarti optimizer mudah menemukannya. Pada plain CNN, optimisasi komposisi banyak transformasi dapat menjadi sulit, sehingga training error meningkat ketika kedalaman bertambah. Ini merupakan degradation problem, bukan sekadar overfitting, karena performa data latih sendiri memburuk. Residual block mempelajari koreksi F(x) terhadap input melalui $y = x + F(x)$, sehingga solusi mendekati identitas lebih mudah dinyatakan dengan F(x) mendekati nol. Dalam backpropagation, gradien menjadi $dL/dx = dL/dy (I + dF/dx)$. Komponen identitas menyediakan jalur langsung bagi gradien, membantu mengurangi pelemahan akibat perkalian Jacobian berulang. [2]

A3. Feature extraction dan fine-tuning (slide 14-16)

Feature extraction memperbarui classifier saja, sedangkan backbone pretrained dipertahankan. Untuk linear head ResNet-18 dengan 512 fitur dan 10 kelas, jumlah parameter aktif adalah $512 \times 10 + 10 = 5.130$. Kebutuhan data biasanya lebih rendah karena sedikit parameter dipelajari. Forward backbone tetap diperlukan, tetapi gradien backbone dan state optimizer-nya tidak disimpan, sehingga beban memori dan komputasi training lebih ringan. Fine-tuning membuka sebagian atau seluruh backbone, meningkatkan parameter aktif, kebutuhan memori, dan potensi penyesuaian terhadap domain target. LR besar berisiko merusak fitur pretrained dan memicu overfitting. Pilih feature extraction sebagai awal ketika data terbatas dan domain cukup mirip. Pertimbangkan fine-tuning bertahap ketika validation menunjukkan keterbatasan representasi dan tersedia data serta anggaran komputasi memadai. Manfaatnya harus dibuktikan melalui eksperimen. [3,4]

A4. Augmentasi dan label (slide 20-22)

Augmentasi pada train set memperluas variasi tampilan yang dilihat optimizer tanpa mengubah label yang sah. Validation dan test menggunakan transformasi deterministik agar perubahan skor mencerminkan perubahan model, bukan sampel transformasi acak yang berbeda. Validation dipakai untuk pemilihan checkpoint, sedangkan test mengestimasi generalisasi setelah keputusan model dikunci. Augmentasi acak pada keduanya membuat perbandingan lebih bervariasi dan mengubah distribusi evaluasi. Test-time augmentation merupakan protokol tersendiri yang harus ditetapkan dan dilaporkan. Bukan alasan untuk mencampurkan augmentasi training ke evaluasi standar. Contoh transformasi tidak layak untuk klasifikasi ras hewan adalah crop ekstrem yang menyisakan latar belakang dan membuang seluruh hewan. Label ras tetap tertera, tetapi informasi visual yang mendukungnya hilang sehingga pasangan citra-label menjadi tidak bermakna. Bahkan crop moderat perlu diperiksa secara visual agar ciri kepala atau pola bulu tidak selalu terpotong. [4]

A5. Catastrophic forgetting (slide 28-29)

Catastrophic forgetting terjadi ketika pembaruan untuk tugas target menggeser representasi pretrained sehingga kemampuan atau fitur yang sebelumnya berguna hilang. Pada data kecil, gradien dapat didominasi pola spesifik sampel dan mendorong parameter menjauh dari representasi yang dapat digeneralisasi. Strategi pertama adalah differential learning rate: gunakan langkah lebih kecil pada backbone dibandingkan classifier baru. Backbone memerlukan penyesuaian hati-hati, sedangkan classifier perlu belajar pemetaan label target dari awal. Strategi kedua adalah gradual unfreezing: latih head terlebih dahulu, kemudian buka blok atas dan pertimbangkan blok lebih awal hanya bila validation mendukung. Ini mengurangi paparan fitur umum terhadap gradien awal dari head yang belum terlatih. Keduanya tidak menjamin bebas forgetting. Gunakan early stopping dan monitor validation. Penurunan performa target saja juga tidak membuktikan forgetting terhadap tugas sumber tanpa evaluasi tambahan. [3,4]

B. Dataset dan protokol eksperimen

Oxford-IIIT Pet [5]: 1.981 citra, 10 kelas. Kucing: Abyssinian, Bengal, Birman, Bombay, British Shorthair. Anjing: Beagle, Boxer, Chihuahua, Pug, Shiba Inu. Official trainval dan test digabung, lalu dibagi stratified 70/15/15: 1.386 train, 297 validation, 298 test. Seed 42. Hasil memakai split internal, bukan benchmark official test.

ResNet-18 memakai ImageNet1K V1, input 224 × 224 dan normalisasi ImageNet. Batch 32, AdamW, weight decay 0,01, cross entropy, maksimum 25 epoch, patience 4. Checkpoint dipilih dari minimum validation loss. Statistik BatchNorm pretrained dibekukan. BatchNorm B1 tetap dilatih.

Train: Resize 256, RandomResizedCrop 224 (scale 0,8-1), horizontal flip 0,5, rotasi ±15°, brightness/contrast jitter 0,2. Validation/test: Resize 256, CenterCrop 224. B4 tanpa augmentasi memakai transformasi evaluasi. B3 sekaligus menjadi B4 dengan augmentasi. Split, seed dan hyperparameter keduanya sama.

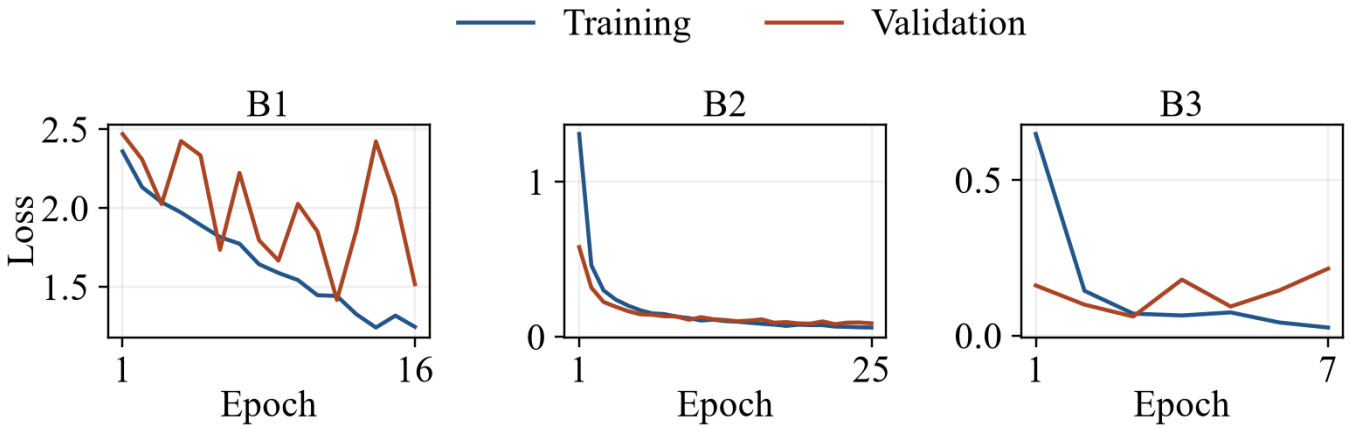
B3 membuka layer4 dan fc sejak epoch pertama. Tidak menerapkan gradual unfreezing beberapa tahap atau scheduler. B5 memakai MobileNetV3-Small [6], membuka tiga blok features terakhir dan classifier, mengikuti konfigurasi ResNet terpilih tanpa augmentasi.

Eksperimen dijalankan secara local pada RTX 5070 Ti dengan PyTorch 2.7.1+cu128 dan FP32. Cache citra, augmentasi, training dan inferensi memakai CUDA. CPU menangani decoding, kontrol program dan ekspor metrik. Eksperimen tidak memakai Colab T4.

C1. Hasil eksperimen dan kurva pembelajaran

Run	Strategi	Parameter aktif	LR	Epoch best/run	Detik	Val acc (%)	Test Macro F1
B1	Scratch	11.181.642	1e-3	12/16	126.73	52.86	0.4872
B2	FE	5.130	1e-3	22/25	158.55	97.98	0.9831
B3	FT	8.398.858	1e-4 / 1e-3	3/7	47.18	98.32	0.9797
B4-	FT	8.398.858	1e-4 / 1e-3	6/10	26.35	98.32	0.9798
B5	FT	1.245.738	1e-4 / 1e-3	3/7	20.39	96.97	0.9498

FE: feature extraction. FT: fine-tuning. B4-: tanpa augmentasi. B3 = B4+. LR FT: blok akhir / head. B2 mencapai batas 25 epoch. Kondisi lain berhenti dini. Epoch berhenti tidak selalu menunjukkan konvergensi.



Durasi mencakup training, evaluasi validation/train bersih dan logging/checkpoint. Tidak termasuk download, inisialisasi dan test. Total lima run: 379,21 detik (6 menit 19 detik).

C2. Analisis komparatif

B1 mencapai validation accuracy 52,86%, jauh di bawah B2 (97,98%) dan B3 (98,32%). Pada 1.386 citra latih, fitur pretrained lebih efektif daripada mempelajari semua fitur dari nol (slide 16). Semua kondisi memakai residual connection. Hasil ini tidak mengisolasi manfaat skip connection (slide 10-12).

B2 memperbarui 5.130 parameter dan memperoleh test F1 tertinggi, 0,9831. B3 memiliki validation loss lebih rendah, tetapi setelah epoch terbaik ke-3, loss berfluktuasi hingga 0,2154 pada epoch 7. Ini menunjukkan fine-tuning memerlukan pengawasan validation (slide 28), bukan bukti catastrophic forgetting. B2 lebih lama total karena berjalan 25 epoch, dibandingkan 7 pada B3.

Augmentasi mengurangi gap train bersih-validation dari 1,68 menjadi 0,17 poin persentase. Namun, validation accuracy sama (98,32%) dan test F1 hampir identik (0,9797 versus 0,9798). Penurunan gap berasal dari akurasi train yang lebih rendah. Manfaat augmentasi pada akurasi evaluasi belum terlihat pada run ini (slide 20).

C3. Analisis enam kesalahan prediksi

B4- dipilih sebelum test karena validation loss terendah (0,05769). Model benar pada 292 dari 298 citra test. Berikut seluruh enam kesalahan, diurutkan menurut confidence. Gambar menunjukkan center crop input. Confidence softmax belum dikalibrasi.



1. Aktual: British Shorthair
Prediksi: Bombay
Confidence: 97.09%



2. Aktual: Chihuahua
Prediksi: Shiba Inu
Confidence: 96.70%



3. Aktual: Boxer
Prediksi: Pug
Confidence: 71.40%



4. Aktual: Chihuahua
Prediksi: Beagle
Confidence: 70.09%



5. Aktual: Chihuahua
Prediksi: Pug
Confidence: 67.56%



6. Aktual: Abyssinian
Prediksi: Bengal
Confidence: 61.02%

Hipotesis berdasarkan pengamatan visual

1. Bulu tampak sangat gelap dan wajah kurang jelas. Pencahayaan dapat menyamarkan ciri British Shorthair sehingga menyerupai Bombay.

2. Bulu cokelat, telinga tegak dan kepala menyamping dapat menyerupai Shiba Inu. Ciri wajah Chihuahua kurang terlihat.

3. Boxer tampak kecil dalam gambar dengan latar ramai. Detail wajah sulit dikenali dan moncong pendek dapat menyerupai Pug.

4. Sudut tubuh dan kepala membuat ciri telinga Chihuahua kurang menonjol. Bentuk kepala dan pola warna dapat ambigu dengan Beagle.

5. Wajah gelap, mata besar dan moncong pendek menyerupai Pug. Aksesori di leher juga menutupi sebagian tubuh.

6. Kain menutupi bagian bawah wajah Abyssinian. Pola di wajah dapat menyerupai Bengal. Oklusi mengurangi petunjuk ras.

Hipotesis ini belum diuji secara kausal. Gambar saja tidak membuktikan fitur mana yang digunakan model.

C4. Rekomendasi rekayasa dan batasan

Untuk domain citra hewan dengan sedikit data berlabel, mulai dari feature extraction (slide 29). B2 hanya melatih 5.130 parameter dan menghasilkan test Macro F1 0,9831. Ini menjadi pilihan awal yang masuk akal ketika memori training terbatas dan fitur ImageNet sudah sesuai. Backbone tetap melakukan forward pass, sehingga pembekuan tidak menghapus seluruh biaya komputasi.

Uji fine-tuning blok atas dengan LR lebih kecil apabila validation menunjukkan perlunya adaptasi. Berdasarkan aturan pemilihan yang ditetapkan sebelum test, model terpilih tetap B4-, meskipun B2 kemudian memperoleh test F1 lebih tinggi. Mengganti pemenang berdasarkan test akan mencampurkan pemilihan model dan evaluasi akhir. Simpan checkpoint validation terbaik untuk menghindari penurunan setelah epoch optimal.

B5 memakai 1.528.106 parameter total, dibandingkan 11.181.642 pada ResNet-18. Parameter aktifnya 1.245.738. Waktu 20,39 detik versus 26,35 detik pada B4-, tetapi test F1 turun dari 0,9798 menjadi 0,9498. MobileNet layak dipertimbangkan bila ukuran model diprioritaskan. Durasi tersebut mencakup 7 versus 10 epoch. Latensi inferensi dan penggunaan daya belum diukur.

Batasan: satu seed, satu split internal, 10 kelas, tanpa interval kepercayaan atau uji domain baru. B2 mencapai batas epoch. BatchNorm pretrained dibekukan dan cakupan blok MobileNet berbeda. Kemiripan domain dengan ImageNet membantu transfer tetapi membatasi generalisasi ke domain lain. Tidak ada pengujian tugas sumber untuk membuktikan forgetting. Waktu GPU local tidak setara Colab T4. Grad-CAM opsional tidak dilakukan.

Referensi

[1] Ioffe & Szegedy (2015). Batch Normalization.

[2] He et al. (2016). Deep Residual Learning for Image Recognition.

[3] Yosinski et al. (2014). How transferable are features in deep neural networks?

[4] PyTorch. Transfer Learning for Computer Vision Tutorial.

[5] Parkhi et al. (2012). Cats and Dogs. Oxford-IIIT Pet.

[6] Howard et al. (2019). Searching for MobileNetV3.

[7] Hidayaturrahman. Materi Sesi 05: Advanced CNNs and Transfer Learning, slide 6-29. Catatan: augmentasi terdapat pada slide 20-22. Slide 23 berjudul Modern Architectures.

Pernyataan Penggunaan AI

AI membantu saya mengerjakan dan memahami code. Alat: OpenAI Codex. AI juga membantu menyusun laporan. Verifikasi mandiri: menjalankan notebook, mempelajari code, dan mencocokkan metrik.

Repository GitHub: classification-oxford-race (klik untuk membuka).